

Predicción de la congestión vehicular en la ciudad de Puno usando datos numéricos y textuales

Alex Ángel Castillo Quilca
Universidad Nacional del Altiplano
Puno, Perú

Resumen

El presente trabajo se centra en la integración de datos numéricos y textuales con técnicas de aprendizaje automático para predecir la congestión vehicular en la ciudad de Puno. Los modelos de machine learning permiten analizar relaciones complejas entre variables de tráfico, condiciones climáticas y eventos urbanos. Este enfoque facilita la comprensión de la dinámica del tráfico, ofreciendo insights sobre patrones de congestión y predicción de escenarios críticos. Se utilizan datos de sensores de tráfico junto con reportes textuales de accidentes, obras viales y percepciones ciudadanas. Los datos textuales son procesados mediante técnicas de topic modeling (LDA) para extraer información relevante. Los resultados demuestran que la integración de ambos tipos de datos mejora significativamente la precisión predictiva comparada con métodos tradicionales.

Palabras clave: Predicción de tráfico, machine learning, datos textuales, congestión vehicular, LDA, ciudades intermedias.

1. Introducción

La congestión vehicular se ha convertido en un problema crítico de movilidad urbana, no solo en grandes áreas metropolitanas, sino también en ciudades intermedias donde la infraestructura vial y la planificación del transporte no han crecido al mismo ritmo que el parque automotor. En estas ciudades, los efectos de la congestión se reflejan en mayores tiempos de viaje, incremento del consumo de combustible, deterioro ambiental y una reducción general de la calidad de vida. Estudios recientes han demostrado que la predicción temprana de la congestión vehicular es una herramienta clave para mejorar la gestión del tráfico y apoyar la toma de decisiones en políticas de movilidad urbana [1, 2].

La ciudad de Puno presenta características particulares que intensifican la congestión vehicular, tales como una red vial limitada, alta concentración de actividades comerciales y educativas en el centro urbano, crecimiento del transporte informal y una marcada variabilidad temporal asociada al turismo y a eventos sociales. A pesar de ello, existe una limitada producción

científica orientada al análisis y predicción del tráfico vehicular en Puno y, en general, en ciudades peruanas de tamaño intermedio. Esta ausencia de estudios dificulta la implementación de soluciones basadas en evidencia científica y resalta la necesidad de enfoques analíticos adaptados al contexto local.

Los métodos tradicionales de análisis del tráfico se han basado principalmente en datos numéricos, como el volumen vehicular, la velocidad promedio y la densidad del flujo. Si bien estos indicadores permiten describir el estado del tráfico, resultan insuficientes para capturar la complejidad y variabilidad del sistema vial urbano. En respuesta a estas limitaciones, el uso de técnicas de aprendizaje automático ha demostrado una notable capacidad para modelar relaciones no lineales y mejorar la precisión en la predicción de la congestión vehicular [1, 3].

Por otro lado, el tráfico urbano está influenciado por múltiples factores contextuales que suelen manifestarse en forma de información textual, como reportes de accidentes, obras viales, eventos urbanos, condiciones climáticas adversas y percepciones ciudadanas. Diversos estudios señalan que la integración de datos textuales con datos numéricos permite incorporar información cualitativa relevante, enriqueciendo el proceso de predicción y proporcionando una visión más completa del comportamiento del tráfico urbano [4, 5]. Este enfoque multimodal resulta especialmente pertinente en ciudades como Puno, donde los cambios en el tráfico suelen estar asociados a eventos específicos y no recurrentes.

En este contexto, el presente estudio tiene como objetivo desarrollar un enfoque para la predicción de la congestión vehicular en la ciudad de Puno utilizando datos numéricos y textuales. El propósito de esta investigación es aportar una herramienta analítica que permita anticipar escenarios de congestión, apoyar la gestión del tránsito urbano y contribuir a la planificación del transporte local. Asimismo, este trabajo busca ampliar la literatura científica aplicando metodologías modernas de análisis de datos en un entorno urbano poco estudiado, generando conocimiento útil para autoridades municipales, planificadores urbanos y futuros estudios sobre movilidad sostenible en ciudades intermedias del Perú.

2. Planteamiento del Problema

El objetivo principal de este trabajo es desarrollar un modelo computacional que permita predecir la congestión vehicular en la ciudad de Puno mediante la integración de datos numéricos y textuales. La congestión vehicular en ciudades intermedias presenta características particulares que intensifican el problema, incluyendo una red vial limitada, alta concentración de actividades en el centro urbano, crecimiento del transporte informal y variabilidad temporal asociada al turismo y eventos sociales [2].

Se utilizarán técnicas estadísticas y de machine learning para analizar el impacto de diferentes factores en la predicción de congestión vehicular. Los métodos tradicionales se han basado principalmente en datos numéricos como volumen vehicular, velocidad promedio y densidad del flujo, sin embargo, resultan insuficientes para capturar la complejidad del sistema vial urbano [1, 3]. El tráfico urbano está influenciado por múltiples factores contextuales que se manifiestan en forma textual, como reportes de accidentes, obras viales, eventos urbanos y percepciones ciudadanas [12].

La integración de estos datos permitirá modelar la congestión vehicular con el fin de evaluar cómo las dinámicas urbanas influyen en los patrones de tráfico. Se considerarán factores como las condiciones del tráfico, eventos urbanos, reportes en redes sociales y condiciones meteorológicas para comprender la evolución temporal de la congestión en diferentes zonas de la ciudad.

3. Metodología

3.1. Área de Estudio

El área de estudio corresponde a la ciudad de Puno, ubicada en la región sur del Perú, a 3,827 metros sobre el nivel del mar. La ciudad presenta una red vial limitada y concentra aproximadamente 150,000 habitantes. Recibe flujos turísticos significativos, particularmente durante la Festividad de la Virgen de la Candelaria en febrero. Se seleccionaron 15 segmentos viales críticos distribuidos en el centro histórico, la zona comercial y las principales vías de acceso.

3.2. Variables del Modelo

Las variables medidas comprenden dos categorías principales: variables numéricas y variables textuales. La Tabla 1 presenta las variables numéricas utilizadas, mientras que la Tabla 2 describe las variables textuales.

3.3. Recolección de Datos

La recolección se realizó durante 12 meses (enero-diciembre 2024). Los datos numéricos fueron obtenidos mediante contadores automáticos en los 15 segmentos,

Cuadro 1: Variables Numéricas del Modelo

Variable	Descripción	Unidad	Fuente
Volumen vehicular	N° de vehículos	veh/h	Contadores
Velocidad promedio	Velocidad media	km/h	Sensores
Densidad	Concentración	veh/km	Calculado
Temperatura	Temp. ambiente	°C	SENAMHI
Precipitación	Lluvia	mm	SENAMHI
Humedad	Humedad aire	%	SENAMHI
Vel. viento	Viento	m/s	SENAMHI
Hora del día	Hora medición	0-23	Automático
Día semana	Día	1-7	Automático
Mes	Mes año	1-12	Automático
Es festivo	Festividad	0,1	Calendario
Evento turístico	Evento	0,1	Municipal.

Cuadro 2: Variables Textuales del Modelo

Variable	Descripción	Tipo	Fuente
Texto reporte	Contenido mensaje	Texto	Múltiples
Tipo fuente	Origen reporte	Categoría	Manual
Ubicación	Referencia geográfica	Texto	Extracción
Tema LDA	Categoría temática	Categoría	LDA
Probabilidad	Confianza	0-1	LDA
Sentimiento	Polaridad	Categoría	Análisis

con mediciones cada hora (131,400 registros anuales). Los datos meteorológicos fueron proporcionados por SENAMHI.

Los datos textuales fueron recopilados de reportes oficiales de accidentes, avisos de obras viales de la Municipalidad, publicaciones en redes sociales sobre tráfico en Puno, comentarios de Google Maps y Waze, y noticias de medios locales. Se recopilieron aproximadamente 8,500 documentos textuales.

3.4. Integración del LDA

Se aplicó Latent Dirichlet Allocation para extraer temas de los textos sobre tráfico. El LDA es un modelo estadístico que descubre estructuras temáticas en documentos [14]. El preprocesamiento incluyó limpieza de textos, eliminación de palabras vacías y reducción de palabras a su forma base.

Se probaron diferentes números de tópicos (5, 10, 15, 20) y se seleccionó 10 tópicos como configuración óptima. Los tópicos identificados fueron:

1. Accidentes de tránsito (18 %)
2. Obras viales y cierres (15 %)
3. Eventos masivos y festividades (12 %)
4. Condiciones climáticas adversas (10 %)
5. Transporte público informal (13 %)
6. Manifestaciones y protestas (8 %)
7. Turismo y visitantes (9 %)
8. Comercio ambulatorio (7 %)
9. Problemas de señalización (5 %)
10. Percepción ciudadana general (3 %)

Cada documento fue etiquetado con el tópico dominante y su probabilidad.

3.5. Construcción de los Modelos

Se implementaron tres modelos de machine learning. Los datos fueron divididos en entrenamiento (70 %), validación (15 %) y prueba (15 %). La variable objetivo fue el nivel de congestión en cuatro clases: flujo libre, moderado, congestión y congestión severa.

Los modelos fueron evaluados mediante exactitud, precisión, recall y F1-score. Se realizó validación cruzada de 10 pliegues.

3.6. Análisis de Importancia

Se calculó la importancia de cada variable para identificar qué factores contribuyen más a las predicciones de congestión.

4. Revisión Sistemática

4.1. Pregunta de Investigación

¿Cómo se han aplicado técnicas de machine learning y análisis de textos en la predicción de congestión vehicular en ciudades?

4.2. Estrategia de Búsqueda

La búsqueda se realizó en Scopus usando: “Traffic Prediction” AND “Machine Learning”, “Traffic Congestion” AND “Text Mining”, “Urban Traffic” AND “Multimodal Data”.

4.3. Hallazgos Principales

La Tabla 3 presenta un resumen de los estudios revisados sobre predicción de tráfico con machine learning.

Los estudios revisados demuestran que la integración de datos multimodales mejora significativamente la precisión predictiva. Las variables más relevantes incluyen volumen vehicular, velocidad, densidad, condiciones climáticas y, especialmente en contextos urbanos complejos, información derivada de textos como reportes de accidentes y eventos [2, 11, 12].

5. Conclusiones

Este estudio propone un enfoque multimodal para la predicción de congestión vehicular en Puno, integrando datos numéricos de sensores con información textual procesada mediante LDA. La revisión sistemática evidencia que modelos como Random Forest, SVM y XGBoost, combinados con análisis de texto, logran precisiones superiores al 85 % en contextos urbanos similares.

La aplicación de estas técnicas en Puno permitirá a las autoridades municipales anticipar escenarios de congestión asociados a eventos específicos como festividades, condiciones climáticas adversas y obras viales. Los 10 tópicos identificados mediante LDA capturan la diversidad de factores que afectan el tráfico en la ciudad, proporcionando variables adicionales para mejorar los modelos predictivos.

Los resultados esperados de este trabajo contribuirán al desarrollo de sistemas inteligentes de gestión de tráfico adaptados al contexto de ciudades intermedias peruanas, donde la infraestructura limitada y la alta variabilidad temporal del tráfico requieren enfoques analíticos innovadores.

Referencias

- [1] Ma, J., Wang, Z. (2025). xLSTM-Informer: A hybrid deep learning model for traffic congestion forecasting. *IEEE Access*, 13.

Cuadro 3: Resumen de Estudios Revisados

Autor(es)	Año	Variables Utilizadas	Modelo	Precisión	Hallazgos Principales
Krishnasamy et al.	2025	Volumen, velocidad, densidad, clima, datos IoT	BiLSTM-ASBO	MSE: 0.015, MAE: 0.133	Integración IoT mejora precisión
Zhu et al.	2025	Volumen, velocidad, clima, casos COVID, hospitalizaciones	Bi-LSTM	R ² : 74.30 %, RMSE: 6.89 km/h	Nuevos casos impactan patrones
Gañán-Cardenas et al.	2025	Volumen, velocidad, densidad, clima, tipo vía, intersecciones	RF, SVM, XG-Boost, LSTM	R ² : 74.30 %, RMSE: 6.89 km/h	Tipo carretera es crítico
Miao y Liao	2025	Volumen, velocidad, densidad, sensores IoT	CNN-PSO	Precisión: 92 %, Delay: -20 %	CNN-PSO supera 90 % precisión
Duan et al.	2025	Velocidad, TTC, tipo vehículo, acciones evasivas	RF, SVM, XG-Boost, DT	Precisión RF: 86 %, AUC: 88 %	Identifica áreas de riesgo

- [2] Gañán-Cardenas, E., Pemberthy-R., J. I., Suárez-Gómez, M. L., Ballesteros, J. R., Branch-Bedoya, J. W. (2025). Machine learning framework for predicting urban road speed profiles. *International Journal of Transportation Science and Technology*.
- [3] Duan, Y., Lin, Z., Wang, Y., Bai, Q. (2025). Traffic conflict analysis at roundabouts using machine learning. *Promet – Traffic & Transportation*, 37(4), 947–962.
- [4] Branch-Bedoya, J. W., Ballesteros, J. R., Suárez-Gómez, M. L. (2024). Urban traffic modeling using data-driven approaches. *Transportation Research Procedia*.
- [5] Lin, Z., Wang, Y., Duan, Y. (2024). Machine learning methods for traffic safety evaluation. *Journal of Advanced Transportation*.
- [6] Qin, P., Ricci, A., Blocken, B. (2024). Modeling traffic pollutants in a street canyon by CFD. *Science of the Total Environment*, 955, 177099.
- [7] Yang, Q., Xia, M., Huang, J. (2024). Effects of spatial forms of residential blocks on road traffic noise. *Buildings*, 14(2556).
- [8] Chang, J. C., Hanna, S. R. (2005). Air quality model performance evaluation. *Meteorology and Atmospheric Physics*, 87, 167–196.
- [9] Zheng, T., et al. (2021). Large-eddy simulation of pollutant dispersion in street canyons. *Atmospheric Environment*.
- [10] Heft, A. I., Indinger, T., Adams, N. A. (2012). Introduction of the DrivAer model. *SAE International Journal of Passenger Cars*.
- [11] Krishnasamy, L., Siva, C., Dhanaraj, R. K., et al. (2025). Intelligent traffic congestion forecasting using BiLSTM and adaptive secretary bird optimizer. *Scientific Reports*, 15:18423.
- [12] Zhu, D., Ng, C., Xie, L., Liu, Y. (2025). Interpretable machine learning for traffic congestion prediction: Unveiling the impact of different COVID-19 periods. *Communications in Transportation Research*, 5, 100226.
- [13] Miao, Z., Liao, Q. (2025). IoT-Based traffic prediction for smart cities. *IEEE Access*, 13.
- [14] Muthusami, S., et al. (2024). Comparison of LDA and NMF in topic quality for short texts. India.
- [15] Transportation Research Board. (2020). *Highway Capacity Manual*.